

AI 时代数学成果的稳健残差评价体系

AI 工作剔除、评分聚合与稳定排序

整理：Qi Guo

2026 年 8 月

摘要

本文提出一个严格可计算的数学成果评价体系 Sare-Math。体系不试图由文风判断作者是否使用了人工智能，而是把论文拆分为少量核心贡献单元，在冻结的模型、工具、文献与计算预算下进行独立复现，估计每个单元的 AI 可剔除比例。评价同时输出数学结果本身的价值、AI 可复现比例和扣除 AI 工作后的人类剩余贡献。为减小参数和评审人差异，体系采用固定快照、锚点校准、单调回归、稳健中位数、评审一致性门槛、权重多面体和精确线性优化；只有在所有允许参数下仍成立的先后关系才进入正式排名，其余论文归入同一稳健层级。基于此前十五篇近期 arXiv 论文的试算，权重扰动不改变排序，七人评审面板的平均 Kendall 相关系数约为 0.983，而 AI 可复现比例仍是主要不确定性来源。使用五个系统配置、每个提示层级十八次运行后，AI 估计误差降至约 0.029，综合扰动下平均 Kendall 相关系数约为 0.928，前四名集合保持率约为 94%。本文同时给出冻结数据格式和参考程序，使同一评价包的重复运行得到完全相同的分数与层级。

核心原则。评价人类研究贡献时，应先扣除当前标准 AI tools 能够稳定复现的工作，即使这些工作实际上由人工手工完成；但数学结果本身的价值不因其由 AI 得到而消失。因此至少应报告三个量：

$V(P)$: 结果的数学价值, $A(P)$: AI 可剔除比例, $S_H(P)$: 人类剩余贡献。

正确性是硬门槛，不能由重要性、作者声望、期刊、披露情况或其他分数补偿。

1 评价对象与基本原则

AI tools 的能力并不是一个固定常数。同一模型在不同推理档位、工具权限、agent harness、重试次数和计算预算下可以表现为不同系统；模型后端和动态榜单也可能在不改变名称的情况下更新。上传的模型测评报告已经明确指出这类配置差异、可比性分级和非平稳性问题 [1]。因此，任何“AI 能否完成该工作”的判断都必须相对于一个冻结的能力基线，而不能依赖临时对话或单一模型。

另一方面，《Ten Advances in Mathematics and Theoretical Computer Science》明确把十项结果表述为由内部模型获得 [2]。这类案例说明，定理的重要性、证明的技术难度和人类作者的原创贡献可以彼此分离。若不分开评价，就会把模型能力自动转化为人的学术信用，或者反过来因为结果由 AI 得到而低估定理本身。

本文使用以下三条原则。

1. **正确性先于评分。**主定理陈述、证明和外部输入未通过检查时，不进入正式排序。
2. **按能力剔除，而不是按使用声明剔除。**是否披露 AI 使用影响来源判断和透明度，但核心扣除量由冻结能力基线下的独立复现决定。
3. **只报告稳健顺序。**若合理改变权重、评审人或 AI 估计后两篇论文可能互换，则不强行给出精确名次，而把它们放入同一层级。

2 冻结评价包与确定性复现

定义 2.1 (冻结评价包). 一次评价由规范化数据对象

$$\mathfrak{E} = (h_P, \tau_L, B, \mathcal{R}, \nu, \sigma, D)$$

确定。其中 h_P 是论文文件哈希, τ_L 是文献截止时间, B 是 AI 能力基线, $\mathcal{R}$ 是评分规则版本, ν 是评审人和锚点集合, σ 是确定性排序与抽样种子, D 是所有原始评分、AI 运行和核查结果。对规范化 JSON 计算

$$H(\mathfrak{E}) = \text{SHA256}(\text{CanonicalJSON}(\mathfrak{E}))$$

作为评价版本标识。

表 1: 冻结评价包必须记录的元数据。

项目	最低要求
论文对象	PDF/TeX 版本、SHA-256、主定理列表、文献截止时间
AI 系统	模型/API 版本、推理档位、系统提示、工具权限、agent 代码版本
计算预算	最大 token、运行次数、并行数、时间或费用上限、随机种子
检索环境	允许访问的数据库、提交日前文献快照及其哈希
评审环境	评分规则版本、锚点论文、评审人专业范围、匿名化和排序方式
输出精度	内部使用至少 12 位十进制; 只在最终显示时四舍五入

评价程序只读取冻结文件, 不在排版或打分阶段实时访问网络、模型接口或系统时间。任何新的 AI 运行、论文版本、锚点或评审意见都必须产生新的 $H(\mathfrak{E})$; 旧版本不可被静默覆盖。

命题 2.2 (同包确定性). 若两个计算使用同一规范化评价包 $\mathfrak{E}$ 、同一规则版本和同一算术精度, 则 Sare-Math 输出的中心分数、区间、稳健支配关系和层级完全相同, 与当天编译或执行次数无关。

证明. 主评分过程只由有限次加减乘除、中位数、固定的单调回归和有限权重顶点上的极值组成, 均是 $\mathfrak{E}$ 的确定函数。排版文件只读取已经冻结的结果, 不产生新数据。因此相同输入给出相同输出。若要求 PDF 文件本身也尽量逐字节一致, 可固定 SOURCE_DATE_EPOCH 并删除动态创建时间; 这不影响数学分数。□

参考实现使用 28 位十进制计算中心分数, 并精确枚举权重多面体的有理顶点。对试算数据连续执行二十次, 结果 JSON 的 SHA-256 均为

$$005f4a027f93c208b9c58182b1e832536fd99fd4b220726c8cd4375b1346295f.$$

3 正确性门槛与核心贡献图

3.1 正确性门槛

每篇论文先获得状态

$$G(P) \in \{\text{fail}, \text{provisional}, \text{pass}\}.$$

若存在推翻主定理的错误, 则记为 *fail*。若关键步骤尚未独立核查, 或存在可能可补但尚未补齐的主要缺口, 则记为 *provisional*。只有主定理陈述、逻辑链和主要外部输入均通过核查时, 才记为 *pass*。只有 *pass* 进入正式排名; *provisional* 只报告暂定区间。

3.2 主定理证明的最小贡献图

设论文有中心定理族 $T_1, \dots, T_m$ 。把主证明压缩为有向无环图

$$\mathcal{G}_P = (V, E),$$

其中节点只保留不可缺少且非标准的数学单元：删除该节点后，至少一个中心定理在当前路线下失去证明，并且该节点不能由提交日前的标准引用直接替代。常规背景、重复动机和不改变路线的计算不单独成节点。

节点类型和基准权重如下。

表 2: 核心贡献节点的五种类型。

类型	基准权重 b_r	判定标准
问题形成 F	3	选择中心现象、正确表述或新的问题族
决定性观察 O	5	新不变量、变量替换、隐藏等价、反例机制或使搜索空间坍塌的观察
方法或理论 M	4	可复用的证明工具、一般框架、分类或理论结构
技术闭合 T	2	非常规但主要用于闭合现有路线的估计、计算或分类讨论
整合与推广 G	3	把多个结论统一、推广到第二个情形或形成后续研究纲领

对节点 u 再记录作用范围 $s_u \in \{1, 2, 3\}$ ：分别表示只服务一个定理、服务多个中心定理、决定整篇论文或后续计划；记录关键性 $\kappa_u \in \{1, 2\}$ ：分别表示有已知可替代路线、当前证明在删除后整体坍塌。定义

$$w_u = b_{r(u)} s_u \kappa_u, \quad \omega_u = \frac{w_u}{\sum_{v \in V} w_v}.$$

这一设计使一行的绝妙观察可以得到比二十页常规估计更高的权重。评价不按劳动时间或篇幅计分，而按节点对数学搜索空间的改变计分。

两名独立评审人先分别提取图。节点集合的加权 Jaccard 相似度低于 0.70 时，不计算最终分数，必须由第三人协调。最终图取传递约简，通常保留 3–12 个节点。

3.3 证明结构指标

对每个节点赋难度 $d_u \in \{1, \dots, 5\}$ ，对每条连接赋难度 $\ell_e \in \{1, \dots, 5\}$ ：

分数	1	2	3	4	5
d_u	常规	标准	非平凡	较深	新概念
ℓ_e	直接	短桥接	精细	全局依赖	意外综合

定义原始证明结构分数

$$\mathcal{A}(P) = |V| + \sum_{u \in V} d_u + \sum_{e \in E} \ell_e,$$

并单独报告关键路径

$$D_{\text{cp}}(P) = \max_{\pi} \left(\sum_{u \in \pi} d_u + \sum_{e \in \pi} \ell_e \right).$$

正规化证明长度为

$$L_{\text{norm}}(P) = \frac{\text{删除重复说明后的中心证明页数}}{\text{中心定理族数量}}.$$

这些量描述结构和 AI 可达性，不直接奖励复杂性。方法价值中的“结构”项评价的是是否有效组织必要复杂度、是否显著压缩旧证明，以及该结构是否可以复用。

4 AI 工作的严格剔除

4.1 冻结能力基线

能力基线 B 至少包含五个系统配置，并来自不少于三个相互独立的模型家族。一个“系统配置”包括模型、推理档位、工具、agent 结构和预算，而不是只写模型名称。对于高风险评价，标准预算为每个贡献单元、每个提示层级、每个系统十八次独立运行；低成本筛选可先使用三个系统、每层五次运行。

表 3: AI 独立复现的四个提示层级。

层级	给定信息	要检验的能力
H_0	问题、定义和截止日前文献，不给路线	是否能独立发现核心机制
H_1	额外给出可能相关的标准工具	是否能选择和组织已有方法
H_2	给出证明骨架，但遮蔽决定性观察	是否能恢复缺失的核心节点
H_3	给出决定性观察，只要求完成技术闭合	是否能执行、验证并写全证明

每个核心单元预先写出 3–8 个原子核查项。一次运行只有在全部核查项成立、没有错误外部引用，并由两名核查者一致接受时才记为成功；分歧由第三人裁决。适合形式化或可执行验证的单元，以验证器结果优先。

4.2 能力估计

设系统 j 在层级 h 的 n 次运行中成功 x_{juh} 次。中心成功率使用 Jeffreys 平滑

$$\hat{p}_{juh} = \frac{x_{juh} + 1/2}{n + 1}.$$

为避免一个异常系统支配结果，先在系统之间取中位数：

$$\tilde{p}_{uh} = \text{med}_j \hat{p}_{juh}.$$

不确定区间使用 Wilson 区间。对 $\hat{p} = x/n$ 和固定 $z = 1.6448536$,

$$W_{\pm}(x, n) = \frac{\hat{p} + z^2/(2n) \pm z\sqrt{\hat{p}(1-\hat{p})/n + z^2/(4n^2)}}{1 + z^2/n}.$$

分别对各系统求区间后取端点中位数。定义能力剔除率

$$a_u^{\text{cap}} = 0.50\tilde{p}_{u0} + 0.30\tilde{p}_{u1} + 0.15\tilde{p}_{u2} + 0.05\tilde{p}_{u3}.$$

低提示层级权重更大，因为从问题本身恢复路线比在给出关键观察后补技术细节更能说明该贡献已经进入标准 AI 能力范围。

4.3 来源下界

作者披露和可核查记录给出独立的来源下界 a_u^{prov} 。

最终剔除率和整篇论文的 AI 比例为

$$a_u = \max\{a_u^{\text{cap}}, a_u^{\text{prov}}\}, \quad A(P) = \sum_{u \in V} \omega_u a_u.$$

区间端点采用同样的单调运算。没有披露不能证明作者隐藏使用 AI，但也不产生透明度加分；能力基线仍会扣除可以稳定复现的部分。若作者明确记录了模型直接生成的核心单元，则来源下界防止因某次复现实验失败而错误恢复人类信用。

表 4: 来源下界的离散规则。

a_u^{prov}	可核查的来源情况
0	仅语言润色, 或没有证据表明 AI 参与该核心单元
0.25	AI 完成局部计算、文献检索或非决定性引理
0.50	AI 搜索实质影响路线选择, 但关键观察由人给出
0.75	关键构造或主要路线由 AI 产生, 人类进行了显著修复和重证
1	核心单元直接由 AI 生成, 人类主要负责检查、编辑或传播

不能把复现失败等同于人类原创。有限预算下的失败可能来自提示、工具、检索或系统配置不合适。因此 $1 - a_u$ 只是冻结基线下的剩余比例, 不是关于思想来源的绝对证明。高分必须同时由问题形成、决定性观察、时间记录、口头重建和后续理论作用支持。

4.4 顺序停止

AI 运行按每个系统每层六次为一批。若所有层级的加权区间使 $a_u^+ - a_u^- \leq 0.10$, 则停止; 否则运行至十八次。若即使达到上限, 论文之间的稳健层级仍无法确定, 则保留区间, 不继续用无限计算追求虚假精度。

5 评审人校准与稳健聚合

5.1 评审面板

完整评价至少需要七名评审人: 不少于四名本方向专家、两名邻近方向专家和一名方法/AI 评估者。论文顺序、作者信息和来源披露在第一轮中尽可能盲化, 排序由评价包哈希确定。每名评审人需对随机抽取的 20% 项目在若干日后重复评分, 用于检查内部一致性。

5.2 行为锚点与单调校准

每个方向预先建立至少十二个锚点案例, 覆盖 0, 1, 2, 3, 4 五档。评审人先对锚点给出四分之一分辨率的原始分数

$$x_{rak} \in \{0, 0.25, \dots, 4\}.$$

对每个评审人 r 和维度 k , 用 pool-adjacent-violators 算法求单调函数

$$g_{rk} = \arg \min_{g \text{ nondecreasing}} \sum_a (g(x_{rak}) - y_{ak})^2,$$

其中 y_{ak} 是锚点共识分。目标论文的校准分为 $z_{rpk} = g_{rk}(x_{rpk})$ 。留一锚点平均绝对误差超过 0.75 分的评审人在该维度不进入聚合; 若合格评审人少于五名, 则不形成最终分数。

最终中心分和离散半径定义为

$$\hat{x}_{pk} = \frac{1}{4} \text{med}_r z_{rpk},$$

$$\Delta_{pk} = \frac{1}{4} \min \{2, 1.4826 \text{med}_r |z_{rpk} - \text{med}_s z_{spk}| + \text{med}_r e_{rk}\},$$

其中 e_{rk} 是锚点校准误差。于是

$$X_{pk} = [\max(0, \hat{x}_{pk} - \Delta_{pk}), \min(1, \hat{x}_{pk} + \Delta_{pk})].$$

中位数对少数异常评审稳健, 单调校准则消除有人习惯使用窄分布、有人习惯使用极端分数造成的系统偏差。

5.3 一致性门槛

对四分之一分辨率评分，使用归一化平方距离

$$\delta(c, c') = \left(\frac{c - c'}{4} \right)^2$$

计算 Krippendorff 一致性系数

$$\alpha_k = 1 - \frac{D_o}{D_e}.$$

若 $\alpha_k < 0.67$ ，该维度必须重新讨论；若 $0.67 \leq \alpha_k < 0.80$ ，只报告区间和层级；若 $\alpha_k \geq 0.80$ ，可报告中心分。重复评分的加权 κ 低于 0.75 的评审人需重新校准。

6 严格可计算的分数

6.1 六个评价维度

结果级评分包括数学重要性 I 、稳健性 R 和表达整合 E ；每个贡献单元另外评分概念原创性 c_u 、方法价值 m_u 和人的不可替代性 h_u 。所有量归一化到 $[0, 1]$ 。

表 5: 六个维度的核心判据。完整五档锚点见附录。

维度	核心问题
重要性 I	是否改变一个方向的理解、消除真实瓶颈或产生重要后续结论；“著名猜想”只是一种信号
概念原创性 C	是否提出新对象、定义、不变量、坐标、重述或概念压缩
方法价值 M	是否提供可复用工具、显著简化、可迁移证明结构或第二个应用
不可替代人类贡献 H	人是否选择了问题、改变了搜索空间、给出决定性观察并组织成理论
稳健性 R	是否经独立重证、边界检验、计算复核或形式化验证
表达与整合 E	假设和来源是否清楚，证明依赖是否可读，结果是否被正确放入理论结构

方法值可进一步分解为

$$m_u = 0.35m_u^{\text{reuse}} + 0.25m_u^{\text{simpl}} + 0.20m_u^{\text{transfer}} + 0.20m_u^{\text{arch}}.$$

最后一项结合 $\mathcal{A}(P)$ 、关键路径和与既有证明的比较，评价新方法是否把必要复杂度组织为可复用结构，而不是简单奖励证明变长。

6.2 结果价值与人类残差

先定义未扣除 AI 的聚合量

$$C_0 = \sum_u \omega_u c_u, \quad M_0 = \sum_u \omega_u m_u.$$

结果本身的数学价值为

$$V(P) = 100(0.25I + 0.30C_0 + 0.30M_0 + 0.10R + 0.05E).$$

这是数学对象的分数，不因发现者是人还是机器而改变。

扣除 AI 后，定义

$$I_R = (1 - A)I, \\ C_R = \sum_u \omega_u (1 - a_u) c_u, \quad M_R = \sum_u \omega_u (1 - a_u) m_u, \quad H_R = \sum_u \omega_u (1 - a_u) h_u.$$

人类剩余贡献分数为

$$S_H(P) = 100(0.15I_R + 0.20C_R + 0.20M_R + 0.35H_R + 0.05R + 0.05E).$$

H 的权重最高, 因为本体系的主要目的不是再次测量定理本身, 而是判断人类在当前 AI 能力基线之外做了什么。 R 和 E 不被直接乘以 $1 - A$, 因为人类作者仍须承担核查、表述和责任; 但二者合计只有 10%, 不能把机器生成的核心证明转化为高人类贡献。

最终报告至少包含

$$(G, V, A, S_H, [S_H^-, S_H^+], \text{稳健层级}).$$

只给一个总分会混淆“结果重要但主要由 AI 得到”和“结果一般但包含强人类概念创新”这两种不同情况。

7 权重稳定性与精确层级

7.1 允许权重集合

中心权重为

$$w^0 = (15, 20, 20, 35, 5, 5),$$

对应 (I, C, M, H, R, E) 。为避免结论依赖某个精确比例, 允许权重在多面体

$$\mathcal{W} = \left\{ w \in \mathbb{R}^6 \left| \begin{array}{l} \sum_k w_k = 100, \\ 12 \leq w_I \leq 18, 16 \leq w_C, w_M \leq 24, \\ 30 \leq w_H \leq 40, 4 \leq w_R, w_E \leq 6, \\ w_C + w_M \geq 35 \end{array} \right. \right\}$$

内变化。对固定论文, 把评审和 AI 不确定性转成每个维度的区间 $X_{Pk} = [L_{Pk}, U_{Pk}]$ 。

定义精确的分数包络

$$S_P^- = \min_{w \in \mathcal{W}, x \in X_P} w \cdot x, \quad S_P^+ = \max_{w \in \mathcal{W}, x \in X_P} w \cdot x.$$

由于目标函数线性, 极值必在 $\mathcal{W}$ 的顶点取得。本规则下多面体有 50 个有理顶点, 参考程序精确枚举这些顶点, 不依赖随机采样或不同线性规划器的数值细节。

7.2 稳健支配

对论文 P_i, P_j 定义

$$D_{ij}^- = \min_{w \in \mathcal{W}, x_i \in X_i, x_j \in X_j} w \cdot (x_i - x_j).$$

取显示容差 $\delta = 1$ 。若

$$D_{ij}^- > \delta,$$

则称 P_i 稳健支配 P_j 。

命题 7.1 (参数稳定性). 若 P_i 稳健支配 P_j , 则对所有允许的权重、评审区间和 AI 剔除区间, P_i 的人类贡献分均至少高于 P_j 一分。任何在允许参数内的小改动都不能翻转该顺序。

证明. 结论就是 D_{ij}^- 的定义。由于极值在有限有理顶点上取得, 该判断可精确计算。□

把没有被剩余论文稳健支配的论文作为第一层, 删除后重复, 得到层级 $\mathcal{T}_1, \mathcal{T}_2, \dots$ 。同一层内部可以按中心分显示, 但差异不解释为稳定学术顺序。中心分差小于一分时直接记为并列; 若仍需机器排序, 只用论文哈希作为显示规则, 不赋予数学意义。

8 十五篇近期论文的试算

本节沿用此前对十五篇 2026 年 7 月至 8 月初 arXiv 论文的人工初始评分。它只用于测试系统的稳定性, 不构成对论文正确性的最终认证。标题和 arXiv 编号按 2026 年 8 月 7 日摘要页核对; 中心维度、AI 比例和区间是试算输入。

表 6: 十五篇试算论文的结果价值、AI 剔除率、人类残差分和稳健层级。

编号	简称	arXiv	V	A	S_H	稳健包络	层级
P01	Fourier restriction norm method for pathwise SNLW	2607.07618	95.8	0.12	86.4	[80.9, 90.6]	1
P02	KdV periodic waves under localized perturbations	2607.08401	92.7	0.16	81.3	[75.7, 85.8]	1
P03	Lusztig's special pieces conjecture	2607.15406	95.0	0.18	80.7	[74.8, 85.3]	1
P04	Graph-theoretical characterization of subgroups of V	2608.02111	91.4	0.18	78.8	[72.7, 84.1]	1
P05	Cautis–Logvinenko conjecture	2607.25982	85.6	0.24	70.8	[64.2, 76.6]	2
P06	Nine-distance theorem	2608.01443	86.6	0.28	67.9	[60.9, 74.2]	2
P07	Odd-cycle span defect	2608.00691	79.6	0.34	59.9	[52.8, 66.4]	2
P08	Both directions of Fuglede fail in dimension two	2607.15632	84.3	0.42	55.2	[46.2, 63.3]	3
P09	Counterexample to Duncan's conjecture	2607.25118	71.1	0.43	49.6	[41.9, 57.0]	3
P10	Perfect 1-factorisation conjecture, asymptotic form	2607.09459	77.1	0.47	49.0	[43.6, 53.9]	3
P11	Counterexample to the zero-mass conjecture	2607.26549	78.2	0.50	46.9	[41.0, 52.3]	3
P12	Counterexamples to Charpin's conjecture	2607.28741	70.0	0.50	44.1	[36.6, 51.3]	3
P13	Nine-line Jacobian-relation counterexample	2607.01985	58.8	0.68	28.6	[22.6, 34.9]	4
P14	On Feige's conjecture	2607.24528	65.2	0.75	25.5	[21.1, 29.7]	4
P15	Counterexample to Batyrev's conjecture	2607.19184	58.2	0.88	15.6	[12.2, 19.2]	5

表中最重要现象不是中心分的精确小数，而是层级。P01–P04 在所有允许权重和输入区间下构成第一层；P05–P07 为第二层；中间若干论文的包络明显重叠，因此不应强行排成唯一顺序。高 V 但较高 A 的论文，例如 Fuglede 反例，可以同时被描述为重要数学结果和较低的人类剩余贡献，这正是双分数体系要保留的信息。

8.1 稳定性实验

参考实验使用固定的十五篇中心数据。评审模拟包含七名评审人和十二个锚点；每名评审人的打分尺度具有随机偏移、非线性压缩和噪声，并以 12% 概率成为异常评审。AI 模拟把每个论文的 A 分解到四个提示层级，并允许不同系统具有 $\logit$ 尺度的能力偏移。所有实验使用固定种子，共三百次重复。

表 7: 稳定性实验。Kendall τ 越接近 1 越稳定。

扰动来源	平均 τ	10% 分位	前四集合不变	90% 最大位移	平均 $ \hat{A} - A $
仅权重在 W 内变化	1.000	1.000	100%	0	0
七人评审面板重抽样	0.983	0.962	100%	1	0
AI: 1 系统 $\times$ 1 次/层	0.624	0.467	14.3%	9	0.140
AI: 3 系统 $\times$ 9 次/层	0.887	0.829	78.3%	3	0.048
AI: 5 系统 $\times$ 18 次/层	0.928	0.886	96.7%	3	0.029
权重、评审人与推荐 AI 协议同时变化	0.928	0.886	94.3%	3	0.029

实验说明，权重和经过锚点校准的评审人已经不是主要不稳定来源；AI 可剔除比例的估计精度决定了剩余排序。单个系统的一次回答完全不足以支撑学术评价。五个系统配置、每层十八次运行显著改善稳定性，但精确名次仍可能移动两三位，因此最终应使用稳健层级而不是把小数分当作绝对顺序。

9 实际执行协议

1. **冻结对象。**保存论文、文献快照、规则、模型配置和数据哈希。
2. **正确性初筛。**列出中心定理和潜在致命点；未通过者停止评分。
3. **提取贡献图。**两名专家独立给出 3–12 个节点并协调差异。
4. **制定核查项。**每个节点写出原子成功标准和四级提示。
5. **运行 AI 协议。**先低成本筛选；边界论文进入五系统、十八次完整测试。
6. **记录来源。**把作者披露、提示记录、草稿时间和人工修复映射为来源下界。
7. **评审校准。**评审人先完成锚点，使用 PAVA 校准并检查一致性。
8. **计算 (V, A, S_H) 。**内部不提前四舍五入。
9. **精确枚举权重顶点。**计算分数包络和每一对论文的稳健支配。
10. **发布层级和版本。**输出评价包哈希、规则版本、区间、层级和未解决分歧。

对一般 arXiv 筛选，可以先只做结构先验：判断是否为显式反例、有限搜索、现成工具拼接、短依赖图或直接 AI 披露，并给出宽的 A 区间。只有接近期刊、招聘、奖项或重大结果门槛的稿件，才投入完整复现实验。这样把计算资源集中于真正影响决策的边界案例。

10 适用范围与局限

1. **时间依赖。**同一论文的 A_{sub} 和 A_{now} 不同。评价作者历史贡献应使用提交时冻结基线，不能因未来模型变强而追溯性贬值。

2. **领域依赖。** 锚点、核心单元和成功核查项必须由方向专家建立，不能用统一模板代替专业判断。
3. **复现不等于来源。** AI 成功复现说明工作进入当前能力范围；AI 失败不证明思想一定来自人。
4. **重要性不能完全机械化。** I, C, M 仍需要专家判断，但锚点、区间和稳健支配可以限制任意性。
5. **正确性审查不可省略。** 分数体系不代替逐条证明核查；新稿尤其应保持 **provisional** 状态。
6. **层级优先于总排序。** 当包络重叠时，系统有意拒绝给出虚假的精确顺序。

11 结论

AI 时代数学评价的主要技术问题不是再设计一个更复杂的加权平均，而是严格回答“哪些核心贡献已经可以由标准 AI tools 复现”。本文把这一问题转化为冻结系统配置下的分层复现实验，并在贡献单元上进行扣除；再通过锚点校准、稳健中位数、评审一致性门槛和权重多面体的精确优化，控制不同人和不同参数带来的波动。

最终输出不应只是一个名次，而应是

$$(G, V, A, S_H, [S_H^-, S_H^+], \mathcal{T}).$$

其中 V 保留数学结果本身的价值， A 表示当前能力基线下可剔除的工作， S_H 衡量人类剩余贡献， $\mathcal{T}$ 给出只有在全部允许参数下仍成立的稳健层级。这样的体系既不会因为 AI 证明了一个重要定理而否认其数学意义，也不会把可以由模型稳定生成的证明劳动自动转换为人的数学地位。

A 五档行为锚点

表 8: 六个维度的五档锚点。

分数	维度	行为锚点
0	I	只改变局部常数或重述已知结果，没有非平凡后果。
1	I	对狭窄问题有用，但不改变主要理论结构。
2	I	解决本子方向的实质问题或给出多个有用推论。
3	I	消除领域瓶颈、解决中心问题或改变研究路线。
4	I	具有基础性、跨方向影响，或建立长期研究纲领。
0	C	没有新概念，主要是常规执行。
1	C	对已有对象或参数作有限变形。
2	C	非平凡地组合已有思想或给出新的有效重述。
3	C	引入新不变量、表示、坐标、模型或结构等价。
4	C	创造新的数学语言，使一类问题被重新组织。
0	M	只使用标准工具，不能复用。
1	M	有专门技巧，但主要服务当前证明。
2	M	可用于紧邻的一族问题。
3	M	在多个问题或方向中可迁移，或显著简化已有证明。
4	M	形成一般方法、层级、算法或新的研究框架。
0	H	核心单元由 AI 直接产生，人的作用主要是编辑或检查。
1	H	人完成局部修复、路线筛选或常规协调。
2	H	人给出不可缺少的非标准步骤，但大部分路线可由 AI 执行。

分数	维度	行为锚点
3	<i>H</i>	人给出决定性观察、正确重述或核心构造。
4	<i>H</i>	人同时形成问题、概念和理论结构，且冻结基线不能恢复该路线。
0	<i>R</i>	存在未解决的主要缺口或不可复现计算。
1	<i>R</i>	只有单一路线，依赖脆弱数值或未充分核查外部输入。
2	<i>R</i>	证明基本闭合，边界和参数已检查。
3	<i>R</i>	有独立重证、形式化或严格计算复核。
4	<i>R</i>	多条独立路线一致，结果对假设和实现扰动稳定。
0	<i>E</i>	记号、假设或来源不清，无法可靠复核。
1	<i>E</i>	可读但缺少正确文献定位和结构说明。
2	<i>E</i>	陈述清楚，证明可以跟随。
3	<i>E</i>	依赖图、动机、限制和理论关系组织良好。
4	<i>E</i>	形成可作为方向标准入口的概念性表述。

B 确定性算法

给定冻结数据包，主程序执行以下有限步骤。

```
INPUT: canonical assessment packet E
1. verify document hash, rubric version, literature cutoff, and gate G
2. build normalized contribution weights omega[u]
3. for each unit u and hint level h:
compute system-wise Jeffreys means and Wilson intervals
take medians across systems
4. set a[u] = max(capability fraction, provenance lower bound)
5. calibrate accepted raters by PAVA on anchors; aggregate by median
6. compute V, A, and S_H without intermediate rounding
7. enumerate all rational vertices of the admissible weight polytope
8. evaluate exact score bounds and pairwise worst-case differences
9. form robust-dominance graph and peel its zero-indegree tiers
10. write score JSON, CSV, packet hash, and a human-readable report
```

参考程序 `sare_math_reference.py` 实现上述中心计算、PAVA、Wilson 区间、Krippendorff α 、精确权重顶点枚举和稳健层级。试算输入为 `sare_math_pilot.json`，稳定性模拟为 `sare_math_stability_test.py`。

C 试算语料

试算使用以下 arXiv 条目；这些条目仅用于检验评价算法，不表示本文已完成正确性审查。

- P1. [Fourier restriction norm method adapted to controlled paths: stochastic wave equations.](#)
- P2. [Nonlinear stability of periodic waves in the Korteweg–de Vries equation under localized perturbations.](#)
- P3. [Lusztig’s special pieces conjecture.](#)
- P4. [A graph-theoretical characterisation of subgroups of Thompson’s group \$V\$.](#)
- P5. [The Cautis–Logvinenko conjecture.](#)
- P6. [Nine-distance theorem and growth of best-approximation denominators.](#)

- P7. Odd-Cycle Span Defect: A Polynomial Lower Bound and a Square-Root Upper Bound.
- P8. Both directions of Fuglede’s conjecture fail in dimension two.
- P9. A counterexample to a conjecture of Duncan on versal actions.
- P10. The perfect 1-factorisation conjecture holds asymptotically.
- P11. A counterexample to the zero-mass conjecture.
- P12. Counterexamples to Charpin’s Conjecture on BCH codes.
- P13. A nine-line counterexample to a conjecture on the minimal degree of Jacobian relations.
- P14. On Feige’s conjecture.
- P15. A counter-example to Batyrev’s conjecture on the non-negativity of stringy Hodge numbers.

参考文献

- [1] Q. Guo, 前沿生成式 AI 模型能力测评与 “人类 IQ 刻度” 等值分析, 数据快照 2026-07-29, 研究型评估报告.
- [2] OpenAI, *Ten Advances in Mathematics and Theoretical Computer Science*, 2026.
- [3] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association* 22 (1927), 209–212.
- [4] R. E. Barlow, D. J. Bartholomew, J. M. Bremner, and H. D. Brunk, *Statistical Inference under Order Restrictions*, Wiley, 1972.
- [5] K. Krippendorff, *Content Analysis: An Introduction to Its Methodology*, 4th ed., Sage, 2018.
- [6] P. J. Huber and E. M. Ronchetti, *Robust Statistics*, 2nd ed., Wiley, 2009.
- [7] San Francisco Declaration on Research Assessment, *DORA*.
- [8] *Leiden Declaration on Artificial Intelligence and Mathematics*, 2026.